

Introduzione ai Transformer e ai modelli linguistici

Capitolo 1 Cos'è un modello linguistico

Un modello linguistico è un sistema di intelligenza artificiale progettato per prevedere la parola successiva all'interno di una sequenza di testo. Questi modelli non comprendono il significato delle frasi come un essere umano, ma lavorano su rappresentazioni statistiche del linguaggio.

Capitolo 2 I Transformer

L'architettura Transformer è stata introdotta nel 2017 ed è alla base dei moderni modelli linguistici di grandi dimensioni (LLM). Il meccanismo centrale dei Transformer è l'attenzione (attention), che permette al modello di pesare in modo diverso le parole all'interno di una frase.

Capitolo 3 Limiti dei modelli linguistici

I modelli linguistici possono generare risposte plausibili ma errate, un fenomeno noto come hallucination. Questo accade perché il modello non ha accesso diretto a fonti esterne e si basa solo sulle informazioni presenti nel proprio addestramento e nel contesto fornito.

Capitolo 4 Retrieval Augmented Generation (RAG)

La Retrieval Augmented Generation è una tecnica che combina un sistema di recupero documentale con un modello generativo. In un sistema RAG, il modello prima recupera documenti rilevanti da una base di conoscenza e poi genera una risposta basata esclusivamente su tali documenti.

Conclusione

L'uso di RAG permette di ridurre le hallucination e di rendere le risposte dei modelli linguistici più verificabili e affidabili. Tuttavia, la qualità del risultato dipende fortemente dalla qualità dei documenti e dal processo di chunking.